

AI and Deep Learning

Deep Learning

Jeju National University

Yung-Cheol Byun

#----- a neuron

```
w = tf.Variable(tf.random_normal([1]))
```



```
hypo = w * x_data
```

#----- learning

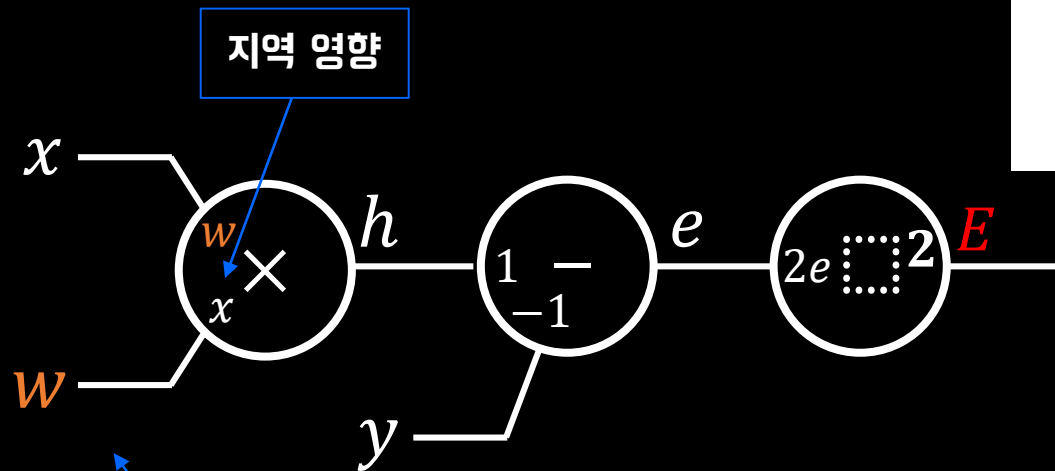
```
cost = (hypo - y_data) ** 2 #cost = Error ( $E$ )
```

$$E = (wx - y)^2$$

오류 계산 그래프




오류 계산 그래프

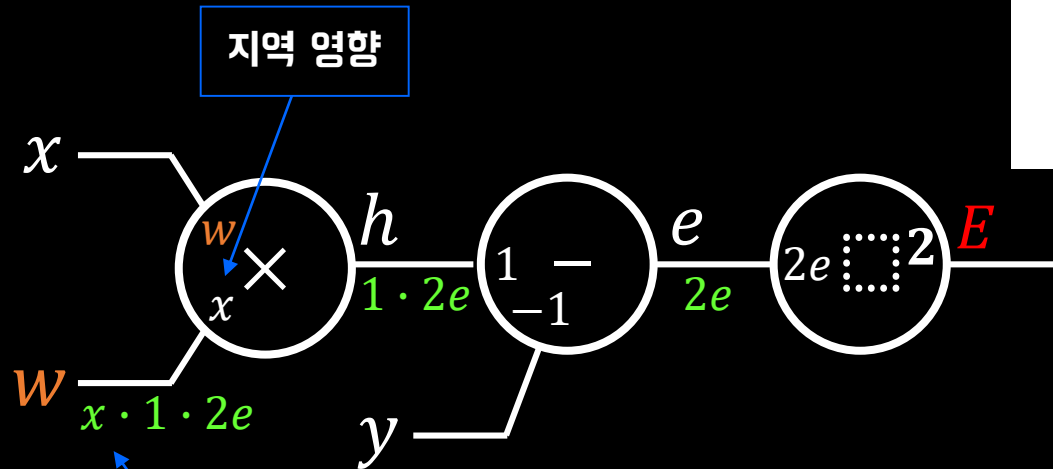


w가 E에 미치는 영향
 = 모든 지역 영향을 곱함 (체인룰)
 = w의 지역 영향 * h가 E에 미치는 영향


$$x * 1 * 2e$$





오류 계산 그래프



w가 E에 미치는 영향
 = 모든 지역 영향을 곱함 (체인룰)
 = w의 지역 영향 * h가 E에 미치는 영향



오류 계산 그래프




$$x * 1 * 2e = x * 1 * 2(wx - y) = 2x(wx - y)$$

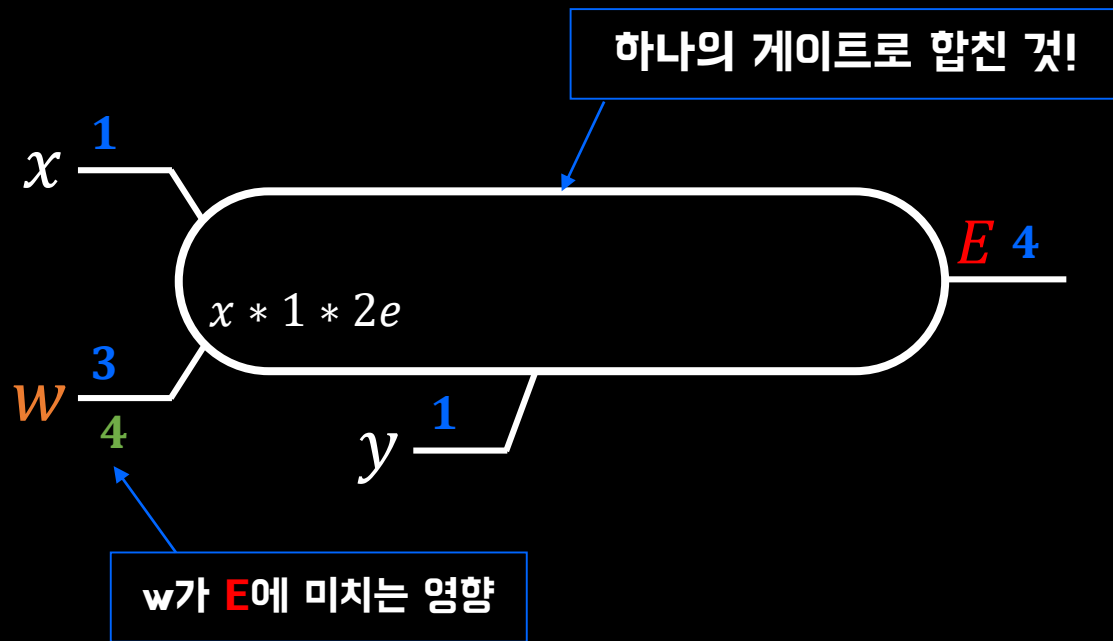
오류 계산 그래프

- 지역 영향(local gradient)는 어떻게 구했나?
- 입력을 1만큼 증가해서 출력이 얼마나 증가하는지 확인해 봄.
- 또는 직접 미분할 수도 있음.

오류 계산 그래프



오류 계산 그래프



$$\times (x + y)^2 = x^2 + 2xy + y^2$$

$E = (wx - y)^2$ 를 미분하면?

$$(wx - y)^2 = w^2x^2 - 2wxy + y^2$$

미분결과 : $2wx^2 - 2xy = 2x(wx - y)$

$$x * 1 * 2e = x * 1 * 2(wx - y) = 2x(wx - y)$$

계산 그래프 또는 미분

- $\text{cost}(E)$ 계산 그래프를 그린 후 w 가 E 에 미치는 영향 구하거나
- 또는 $\text{cost}(E)$ 를 직접 w 에 대하여 미분하여 값을 구하거나

오류 계산 그래프

로지스틱 리그레션
신경 세포 1개만 있을 때

$$\text{cost}(E) = -y \log(\text{hypo}) - (1 - y) \log(1 - \text{hypo})$$

$$\text{hypo} = \frac{1}{1 + e^{-wx}}$$


w가 cost에 미치는 영향은?

w를 아주 조금 바꿨을 때 cost는 어떻게 변하나?

계산 그래프를 그리거나 또는 직접 미분하거나...

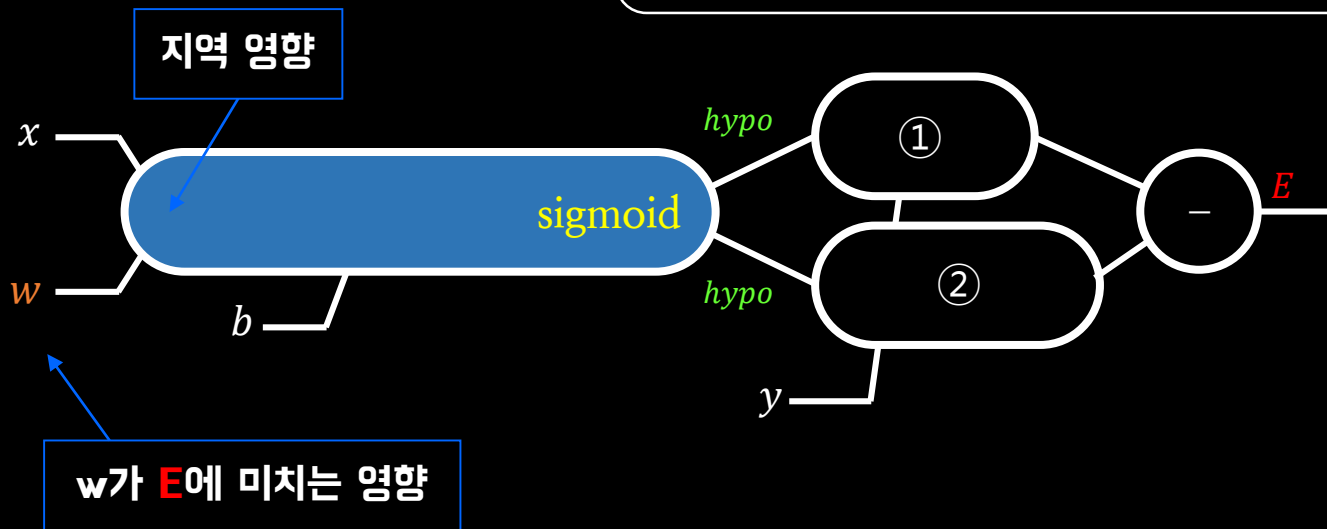
오류 계산 그래프

$$E = -y \cdot \log(\text{hypo}) - \textcircled{2} (1 - y) \cdot \log(1 - \text{hypo})$$




오류 계산 그래프


$$E = -y \cdot \log(\text{hypo}) - \textcircled{1} (1 - y) \cdot \log(1 - \text{hypo}) \textcircled{2}$$




오류 계산 그래프



오류 계산 그래프



오류 계산 그래프



사라지는 영향력 문제

- 수많은 뉴런이 연결
- 그 안에 들어 있는 sigmoid(logistic) function들
- local gradient? logistic function을 미분한 것
 $(1 - \text{logistic}(x)) * \text{logistic}(x)$
- 왼쪽의 w 가 오류에 미치는 영향은?
- 모든 local gradient 를 곱한 것(체인룰)

사라지는 영향력 문제




- 왼쪽의 w 는 수많은 1 이하 수의 곱
- 오른쪽 w 는 큰 문제가 없음
- 왼쪽으로 갈 수록 w 가 E 에 미치는 영향(기울기=gradient)은 매우 작음.
- 즉, 영향력이 사라짐 (Vanishing Gradient)
- $W = W - \alpha * (\text{기울기})$
- 따라서 w, b 가 거의 갱신이 되지 않음

(실습) 18.py

- 4층으로 구성된 신경망으로 XOR 문제를 해결하고자 했으나 Vanishing Gradient 때문에 실패

ReLU

Logistic 함수 대신 **ReLU**를
사용함으로써 Vanishing
Gradient 문제 해결



(실습) 19.py

- ReLU를 이용하여 deep 신경망에서도 역전파 학습이 잘 됨을 보임.


MNIST



Modified National Institute of
Standards and Technology
(USA)



MNIST



MNIST



(실습) 20.py

- 입력으로 주어지는 이미지는 $28 * 28 = 784$ 픽셀
- 따라서 784 차원 입력
- 클래스가 10개(0~9)이므로 신경 세포 수는 10개
- Softmax

(실습) 21.py

- Deep Neural Network (4층)
- ReLU

(실습) 22.py

- 시냅스 가중치(W)와 바이어스(b)를 적절히 초기화

(실습) 23.py

- 시냅스 가중치(W)와 바이어스(b)를 적절히 초기화
- More Deep (DNN) -> 6개 층


오버 피팅(over-fitting)

- 신경망의 깊이와 너비가 클 수록(deep & wide) 결정 경계는 매우 복잡
- 학습 데이터에 대해 지나치게 학습하여 기가 막히게 잘됨
- 하지만 테스트 데이터에 대해서는 에러가 많이 남 -> 오버 피팅


신경 세포가 많을 수록(deep & wide) 결정 경계
복잡하므로 학습 시 신경세포를 배제(drop-out)

Regularization: **Dropout**

“randomly set some neurons to zero in the forward pass”



(a) Standard Neural Net





(b) After applying dropout.


[Srivastava et al., 2014]

(실습) 24.py

- 시냅스 가중치(W)와 바이어스(b)를 적절히 초기화
- More DNN -> 6개 층










Fully connected, so how many connections(parameters) are there?

$$25 * 16 + 16 * 16 + 16 * 9 + 9 * 9 = 881$$







Fully connected, so how many connections are there?

$$25 * 16 + 16 * 16 + 16 * 9 + 9 * 9 = 881$$



Geoffrey Hinton, Yann LeCun, Yoshua Bengio, Andrew Ng



Deep Learning

- in early 2000s (2006, 2010, 2012)
- Deep Neural Networks
- Weight initialization methods
- Activation functions (ReLU)
- Dropout (2014)
- Big data
- GPU