Al and Deep Learning


Deep Learning


Jeju National University Yung-Cheol Byun


```
#---- a neuron
w = tf.Variable(tf.random_normal([1]))
hypo = w * x_data


#---- learning
cost = (hypo - y_data) ** 2 #cost = Error (E)
```


$$E = (wx - y)^2$$

















 $E = (w1 - 1)^2$

기울기, 미치는 영향

$$E = (w \cdot 1 - 1)^{2}$$


$$1 * 1 * 2e = 1 * 1 * 2(w \cdot 1 - 1) = 2(w \cdot 1 - 1)$$

$$\frac{\partial E}{\partial w} = \frac{\partial}{\partial w} E = \frac{\partial}{\partial w} (w \cdot 1 - 1)^2 = 2(w \cdot 1 - 1)$$


기울기, 미치는 영향


- 미치는 영향(기울기, gradient)는 어떻게 구했나?
 - -입력을 1만큼(혹은 아주 조금, 0.00001) 증가해서 출력이 얼마나 증 가하는지 확인해 봄.
 - -또는 직접 미분할 수도 있음.

연산 합치기



연산 합치기






로지스틱 리그레션 신경 세포 1개 있을 때


$$cost(E) = -y \log(hypo) - (1 - y) \log(1 - hypo)$$


$$hypo = \frac{1}{1 + e^{-wx}}$$


w가 cost에 미치는 영향은?


w를 아주 조금 바꿨을 때 cost는 어떻게 변하나? 계산 그래프를 활용하거나 또는 직접 미분하거나...














사라지는 영향력

- Local gradient는 뉴런의 sigmoid function을 미분한 것
- sigmoid를 미분하면 (1-sigmoid(x)) * sigmoid(x)
- sigmoid는 입력 값을 0~1 사이의 값으로 squash
- 따라서 0~1 사이의 값의 곱은?
- 100층 신경망의 경우 100개의 sigmoid 연산


사라지는 영향력


- w가 E에 미치는 양향은 수많은 1 이하의 곱
- 신경망의 왼쪽으로 갈수록 sigmoid가 점점 많아져서 1 이하의 곱이 많아져서 w가 E에 미치는 영향(기울기, gradient)은 거의 0
- 즉, 영향력이 사라짐 (Vanishing Gradient)
- $w = w \alpha \times (미치는 영향~거의 0)$
- 신경망의 왼쪽에 있는 뉴런들의 w,b가 거의 갱신되지 않음

(실습) 18.py

• 4층으로 구성된 신경망으로 XOR 문제를 해결하고자 했으나 Vanishing Gradient 때문에 실패

ReLU





(실습) 19.py

• ReLU를 이용하여 deep 신경망에 서도 역전파 학습이 잘 됨을 보임.

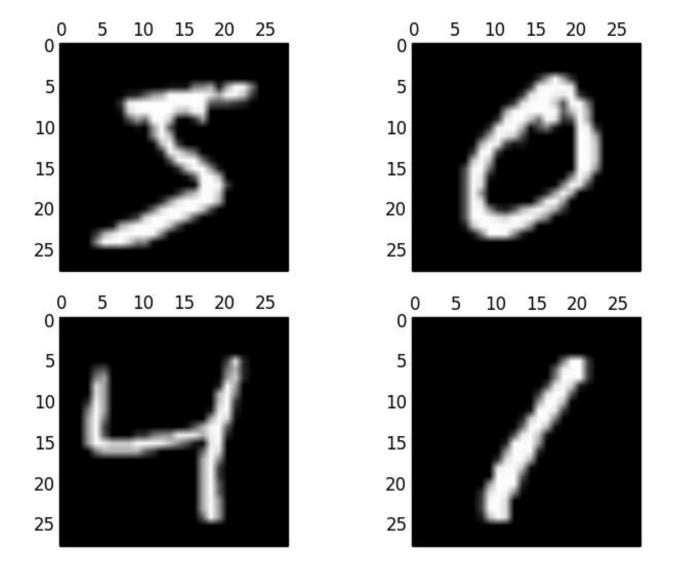
MNIST

Modified National Institute of Standards and Technology (USA)

MNIST








(Lab) 20.py


- 60,000 training images + 10,000 testing images
- Input image : 28 * 28 pixels → 784 pixels
- 784 dimension
- 10 classes (output: 0 ~ 9)
- Softmax
- 90.23% of recognition rate

Input Layer Fully-connected Output Layer h_1 h_2 h_3 h_4 Softmax h_5 h_6 h_7 h_8 h_9 h_{10}



(Lab) 21.py

- Deep Neural Network (4layer)
- ReLU
- 94.55%accuracy




(Lab) 22.py

- 시냅스 가중치(w)와 바이어스
 (b)를 적절히 초기화
- Accuracy: 97.83%

(Lab) 23.py

- 시냅스 가중치(₩)와 바이어스
 (♭)를 적절히 초기화
- Deeper (DNN) -> 6 layers
- 97.23% of accuracy




오버 피팅(over-fitting)

- 신경망의 깊이와 너비가 클 수록(deep & wide) 결정 경계는 매우 복잡
- 학습 데이터에 대해 지나치게 학습하여 기가 막히게 잘됨
- 하지만 테스트 데이터에 대해서는 에러 - 가 많이 남 -> 오버 피팅


신경 세포가 많을 수록(deep & wide) 결정 경계 복잡하므로 학습 시 신경세포를 배제(drop-out)

Regularization: **Dropout**

"randomly set some neurons to zero in the forward pass"



(a) Standard Neural Net




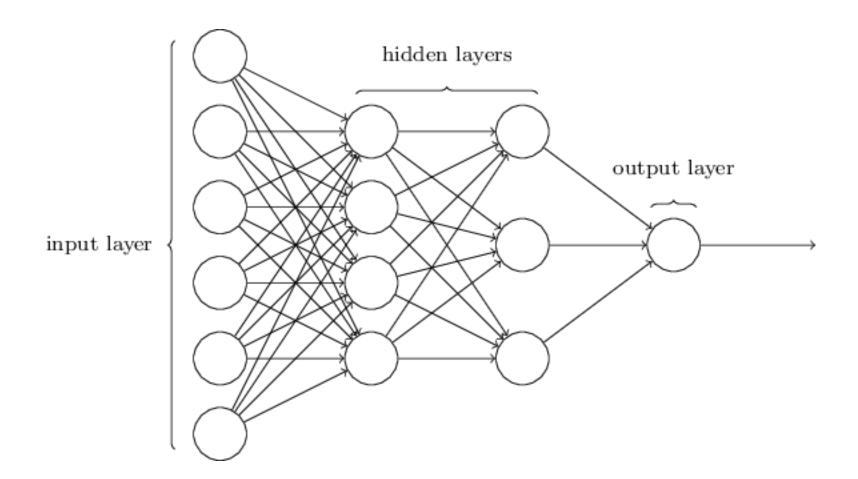
(b) After applying dropout.

[Srivastava et al., 2014]


(실습) 24.py

- 시냅스 가중치(₩)와 바이어스
 (♭)를 적절히 초기화
- Deeper (DNN) -> 6개 층
- Dropout
- 98.13% of accuracy






Input




Fully connected, so how many connections(parameters) are there? 25 * 16 + 16 * 16 + 16 * 9 + 9 * 9 = 881





Fully connected, so how many connections are there? 25 * 16 + 16 * 16 + 16 * 9 + 9 * 9 = 881











Geoffrey Hinton, Yann LeCun, Yoshua Bengio, Andrew Ng









Deep Learning

- in early 2000s (2006, 2010, 2012)
- Deep Neural Networks
- Weight initialization methods
- Activation functions (ReLU)
- Dropout (2014)
- Big data
- GPU